PROGETTO DATA ANALYST

Il Mondo dei Profumi

Analisi di popolarità, tendenze e mercato delle fragranze

— Relazione riepilogativa —

Fasi 1–6: impostazione, pulizia dati, modello, misure DAX, dashboard e rifinitura completa

Carol Pagano

Corso Data Analyst — Epicode · Progetto di portfolio

Panoramica del progetto

Il progetto analizza il mondo dei profumi combinando due fonti di dati reali e pubbliche: **Fragrantica** (l'anima delle fragranze: marche, note, valutazioni) ed **eBay** (il mercato: prezzi e vendite reali). L'obiettivo finale è una dashboard Power BI che risponde a sei domande di analisi, costruita rispettando un principio guida costante: usare solo dati reali, dichiarare onestamente i limiti, evitare complessità che non si può difendere a fondo.

Le sei domande della dashboard

1. Dominio del mercato — quali marche e paesi dominano il mondo dei profumi? 2. Tendenze olfattive — come cambiano le famiglie olfattive nel tempo? 3. Genere e valutazioni — differenze tra profumi uomo/donna/unisex? 4. I più amati — quali profumi hanno valutazione alta e molti voti? 5. Note di successo — quali note ricorrono nei profumi più amati? 6. Prezzi e vendite — cosa si vende di più sul mercato e-commerce?

Fase 1 — Impostazione del progetto

La fase iniziale ha definito obiettivi, fonti dati e limiti metodologici prima di toccare qualsiasi dato.

Le fonti scelte

Fonte	Contenuto	Righe grezze
Fragrantica (fra_cleaned)	Caratteristiche e popolarità dei profumi	24.063
eBay uomo/donna	Prezzi e vendite reali sul mercato di rivendita	1.000 + 1.000

Decisione chiave: niente dati inventati

Fin dall'inizio è stato scartato ogni tentativo di simulare prezzi o costi non disponibili pubblicamente (es. margini di profitto dei brand, listini ufficiali). Dove un dato reale non esiste, il progetto lo dichiara esplicitamente invece di inventarlo — inclusa la scelta di scartare fonti esterne (es. dataset Sephora) trovate non pertinenti dopo verifica diretta del contenuto.

Fase 2 — Pulizia dei dati (Power Query)

Ogni fonte è stata pulita separatamente prima di essere combinata, seguendo una sequenza di passaggi coerente su tutti i file: rimozione spazi e caratteri invisibili, eliminazione duplicati e righe vuote, selezione e rinomina delle colonne utili.

La lezione dei formati numerici

Il problema tecnico più importante affrontato: paesi diversi scrivono i decimali in modo diverso (virgola in Italia, punto negli USA). Applicare la convenzione sbagliata rompe i numeri silenziosamente — es. **84.99** letto all'italiana diventa **8499**. La regola adottata: ogni file va verificato singolarmente, mai per abitudine.

File	Colonna	Convenzione
eBay uomo/donna	Price	Inglese USA (punto decimale)
Fragrantica	Rating Value	Italiano (virgola decimale)

Uniformazione dei brand

I nomi delle marche erano scritti in modo incoerente tra le fonti e persino all'interno della stessa fonte. Sono state applicate correzioni mirate e verificate:

- Maiuscole uniformi su tutti i brand (Text.Proper)
- Correzioni puntuali verificate per varianti dello stesso marchio: es. "Dolce&Gabbana" / "Dolce Gabbana" → "Dolce & Gabbana"; "Giorgio Arm.Ani" → "Giorgio Armani"; "Ysl" → "Yves Saint Laurent"; correzioni di accenti (Lancôme, Hermès, Chloé, Estée Lauder)
- Etichetta "Unknown" per annunci eBay senza marca identificabile (es. "Unbranded", "Multiple Brands") — scelta onesta che mostra il mercato reale invece di nasconderlo
- Formato Fragrantica allineato da trattini minuscoli (jean-paul-gaultier) a marchi leggibili (Jean Paul Gaultier), reso coerente con eBay

Una scelta di metodo importante: quando fermarsi

Durante la pulizia dei brand è stato tentato un recupero automatico delle marche mancanti a partire dai titoli degli annunci eBay, tramite una tabella di corrispondenza codificata. Il tentativo è stato scartato deliberatamente: pur funzionando, produceva codice complesso e poco difendibile per recuperare solo il 2% dei dati. È stata preferita la soluzione più semplice ("Unknown") perché completamente comprensibile e sostenibile. Anche un dataset esterno proposto per arricchire i prezzi (Sephora) è stato scartato dopo verifica: conteneva prodotti skincare, non profumi.

Struttura finale dopo la pulizia

Tabella	Contenuto	Colonne chiave
ebay_mens_perfume	Annunci uomo puliti	Brand, Type, Title, Price, Sold, Gender
ebay_womens_perfume	Annunci donna puliti	Brand, Type, Title, Price, Sold, Gender
fra_cleaned	Profumi Fragrantica puliti	Brand, Perfume, Country, Gender, Rating...

Fase 3 — Il modello dati

Con i dati puliti, il passaggio successivo è stato costruire relazioni affidabili tra le fonti, senza forzare collegamenti fragili.

La decisione di modellazione

Collegare i singoli profumi tra Fragrantica ed eBay riga per riga non era praticabile: i titoli eBay sono annunci liberi e disordinati, non identificatori puliti. La soluzione scelta è stata collegare le fonti a livello di **marca (Brand)**, il livello più fine su cui un aggancio è realmente affidabile.

Le tabelle costruite

- Fact_eBay — unione (Table.Combine) dei file uomo e donna, con colonna Gender per distinguerli
- Bridge_Perfume_Accords — tabella "ponte" costruita con un Unpivot: le 5 colonne mainaccord1-5 di fra_cleaned sono state trasformate in righe (Brand, Perfume, Accord), permettendo di contare facilmente le famiglie olfattive
- Dim_Brand — tabella dimensione con l'elenco unico di tutti i brand (da Fragrantica ed eBay uniti), usata come perno centrale del modello

Lo schema a stella

Il modello finale collega tre tabelle a Dim_Brand tramite relazioni Molti-a-uno a filtro singolo (non bidirezionale), lo standard corretto in Power BI:

Da	A	Cardinalità	Filtro
Fact_eBay	Dim_Brand	Molti-a-uno	Singola
fra_cleaned	Dim_Brand	Molti-a-uno	Singola
Bridge_Perfume_Accords	Dim_Brand	Molti-a-uno	Singola

Perché il filtro "Singola" e non bidirezionale

Una relazione a filtro singolo fa scorrere i filtri in una sola direzione (dalla dimensione verso i fatti), evitando ambiguità di calcolo quando più tabelle sono collegate allo stesso perno. È lo schema "a stella" raccomandato in Power BI, verificato esplicitamente su ciascuna delle tre relazioni.

Fase 4 — Le misure DAX

Con il modello a stella pronto, il passaggio successivo è stato scrivere i calcoli che trasformano le tabelle collegate in numeri pronti per la dashboard: le misure DAX. Sono state create 13 misure in totale (9 di risposta diretta alle domande, 4 di supporto per D2 e D5), organizzate in una tabella dedicata.

Dove vivono le misure

Tutte le misure sono state raccolte in una tabella dedicata, **Misure**, creata con **Misure = {1}** e nascosta dalla visualizzazione report. Separare i calcoli dai dati è una buona pratica: rende il modello più ordinato e più facile da mantenere.

Le misure create

#	Misura	Formula	Risultato
1	Numero Profumi	COUNTROWS(Fra_Cleaned)	24.063
2	Valutazione Media	AVERAGE(Fra_Cleaned[Rating Value])	3,96
3	Numero Voti Totali	SUM(Fra_Cleaned[Rating Count])	12.065.105

4	Prezzo Medio	AVERAGE(Fact_eBay[Price])	43,18 $
5	Pezzi Venduti Totali	SUM(Fact_eBay[Sold])	1.251.032
6	Fatturato Stimato	SUMX(Fact_eBay, Price * Sold)	39.697.251,07 $
7	Numero Marche	DISTINCTCOUNT(Dim_Brand[Brand])	1.173
8	Numero Accordi Distinti	DISTINCTCOUNT(Bridge_Perfume_Accords[Accord])	84
9	Punteggio Più Amati	RatingMedio * LOG(NumeroVoti + 1)	per profumo

Due funzioni nuove: SUMX e il concetto di riga per riga

Le prime cinque misure sommano o mediano una colonna già pronta (SUM, AVERAGE, COUNTROWS). Il Fatturato Stimato è diverso: richiede di moltiplicare prezzo e quantità venduta riga per riga, per ogni singolo annuncio eBay, e poi sommare tutti i risultati. Per questo serve SUMX (la "X" indica che la funzione scorre riga per riga): è la differenza tra sommare una lista di totali già pronti e calcolare il totale di ogni scontrino prima di sommarli.

Contare i valori unici: DISTINCTCOUNT

Per rispondere a "quante marche diverse esistono" o "quante famiglie olfattive esistono" serve contare i valori unici, non tutte le righe di una tabella. DISTINCTCOUNT fa esattamente questo, ed è la scelta concettualmente corretta anche quando, come nel caso di Dim_Brand, il risultato numerico coincide con un semplice conteggio di righe.

Il Punteggio "Più Amati": variabili e logaritmo

La misura più composita risponde alla Domanda 4 della dashboard: quali profumi hanno sia una valutazione alta sia molti voti, non solo l'una o l'altra caratteristica. La formula usa due elementi nuovi:

- VAR / RETURN — permettono di salvare risultati intermedi (rating medio, numero di voti) in variabili con un nome, per poi riusarli nel calcolo finale senza riscriverli.
- LOG() — il logaritmo del numero di voti impedisce che un profumo con moltissimi voti ma rating mediocre schiacci tutti gli altri: appiattisce le differenze enormi, così il rating resta rilevante nel punteggio finale.

```
Punteggio Più Amati =
VAR RatingMedio = AVERAGE(Fra_Cleaned[Rating Value])
VAR NumeroVoti = SUM(Fra_Cleaned[Rating Count])
RETURN RatingMedio * LOG(NumeroVoti + 1)
```

Verifica: i numeri tornano con la Fase 1

Ogni misura è stata controllata confrontando il risultato con i valori dichiarati nella relazione di Fase 1: il Prezzo Medio (43,18 $) e i Pezzi Venduti Totali (1.251.032) combaciano con la fascia "media ~43 $" e "oltre 1,25 milioni" già documentate, e il Numero Profumi (24.063) coincide esattamente con le righe grezze di Fragrantica. Nessuna sorpresa, nessun dato che non torna: segno che la pulizia e il modello delle fasi precedenti reggono.

Una nota di metodo: il Punteggio Più Amati va letto per profumo

Calcolato su tutti i profumi insieme, il Punteggio Più Amati dà un numero riassuntivo (28,05) che è corretto ma poco parlante da solo. Il suo vero scopo emerge quando viene usato dentro una tabella o un grafico filtrato per singolo profumo — la classifica Top 10 costruita nella Domanda 4.

Fase 5 — Dashboard (completa)

Con le misure pronte, la Fase 5 ha costruito i sette grafici/pagine che rispondono visivamente alle sei domande, più la copertina. Questa sezione documenta il lavoro completo, incluse le correzioni tecniche e le scelte di rifinitura fatte in un secondo passaggio dedicato.

Il tema visivo

Prima di creare i grafici è stato impostato un tema colori personalizzato (Profumi_Tema), coerente con la palette di questa relazione, così che ogni nuovo grafico erediti automaticamente lo stile corretto invece di doverlo formattare uno per uno:

- Sfondo pagina: tinta unita quasi bianca (#FAF7F9), per non distrarre dai dati
- Palette a 8 colori: guidata dal viola prugna #6D2E5B (colore 1), con mauve, oro, prugna scura, rosa cipria, verde salvia, beige e magenta come colori di supporto
- Tipografia: Constantia per i titoli (colore prugna, 20pt), Calibri per etichette e assi (grigio scuro, 11pt) — gerarchia visiva chiara tra titoli e dati

> **Convenzione linguistica adottata in fase di rifinitura**
> Le etichette di assi e legende che sono testo libero (non valori del dataset) sono state tradotte in italiano — es. "Year" → "Anno", "Accord" → "Famiglia Olfattiva", "Gender" → "Genere". I VALORI dei dati (men/women/unisex, woody/citrus/aromatic...) restano nella lingua originale del dataset, poiché sono dati e non interfaccia.

Domanda 1 — Dominio del mercato: marche e paesi

Due grafici a barre orizzontali affiancati, entrambi filtrati alle Top 10 (filtro DAX "Primi N" su Numero Profumi), con etichette dati sulle barre:

- Top 10 Marche per Numero di Profumi — asse Dim_Brand[Brand], valori Numero Profumi. Avon (578), Zara (524) e O Boticario (381) in testa.
- Top 10 Paesi Produttori per Numero di Profumi — asse Fra_Cleaned[Country], valori Numero Profumi. Francia, USA e Italia dominano, coerente con l'industria profumiera reale.

Testo di insight aggiunto in rifinitura: **"Avon e Zara guidano per numero di referenze, ma il mercato resta molto frammentato: le prime 10 marche coprono solo il 13% circa dei 24.063 profumi censiti, su un totale di 1.173 marche."** Nota metodologica: **"Il conteggio riflette il numero di profumi presenti su Fragrantica per marca/paese, non necessariamente il volume di vendita o il fatturato."**

Domanda 2 — Tendenze olfattive nel tempo

Grafico a linee con Anno sull'asse X e le 6 famiglie olfattive (Famiglia Olfattiva) in legenda. Ha richiesto tre correzioni tecniche significative, documentate qui perché utili da saper spiegare a colloquio:

- Year mancante nella tabella Bridge — il grafico inizialmente mostrava linee piatte: il modello a stella collega Bridge_Perfume_Accords a Fra_Cleaned solo indirettamente tramite Dim_Brand, quindi i filtri per anno non raggiungevano la tabella Bridge. Soluzione: la colonna Year è stata aggiunta direttamente alla query Bridge_Perfume_Accords in Power Query, così l'anno vive nella stessa tabella degli accordi.
- Numeri assoluti fuorvianti — con conteggi assoluti tutte le famiglie olfattive crescevano insieme (perché il mercato è cresciuto nel complesso), mascherando i cambiamenti di popolarità relativa. Soluzione: la misura % Occorrenze Accordo (con DIVIDE + CALCULATE + ALL) mostra la quota percentuale di ogni famiglia sul totale di quell'anno, indipendente dalla crescita generale.

- Rumore statistico negli anni con pochi dati — filtrare a "dal 1950" non era sufficiente: verificando i valori puntuali (1901 → 4 profumi, 1921 → 8, mentre nel 2000 → 197), è emerso che il campione resta troppo piccolo per generare percentuali stabili fino a fine anni '90. Il filtro è stato quindi spostato a Year ≥ 2000, soglia verificata sui dati reali e non scelta a intuito.

Formula chiave: % Occorrenze Accordo

% Occorrenze Accordo = DIVIDE([Occorrenze Accordo], CALCULATE([Occorrenze Accordo], ALL(Bridge_Perfume_Accords[Accord]))). ALL() rimuove il filtro sulla colonna Accord mantenendo quello sull'anno: il denominatore diventa così il totale di tutte le famiglie in quell'anno specifico, permettendo il calcolo corretto della quota percentuale.

Il grafico finale mostra un andamento pulito dal 2000 al 2019 (ultimo anno con campione pienamente affidabile, 1.496 profumi): woody resta la famiglia dominante ma in relativo calo, mentre aromatic e sweet oscillano nella fascia media. Testo di contesto aggiunto: **"L'analisi parte dal 2000: prima di quell'anno il numero di profumi campionati per anno era troppo basso (talvolta sotto le 10 unità) per generare percentuali stabili."**

Domanda 3 — Genere e valutazioni

Due grafici affiancati: Valutazione Media per Genere e Numero Profumi per Genere. La colonna Gender di Fra_Cleaned è risultata già pulita in fase di verifica (soli 3 valori: men, unisex, women, minuscolo e coerente).

Risultato 1 (valutazione): men 4,0 · unisex 4,0 · women 3,9. Differenza minima — il gradimento dei profumi non varia in modo sostanziale per genere.

Risultato 2 (offerta), aggiunto in rifinitura per dare contesto al primo: women 11,4K profumi · unisex 7,7K · men 5,0K. Il mercato è nettamente sbilanciato verso il segmento femminile, ma questa maggiore offerta non si traduce in valutazioni più alte.

Testo finale: **"Il mercato è nettamente sbilanciato verso il segmento femminile (11,4K profumi women contro 5,0K men e 7,7K unisex), ma questa maggiore offerta non si traduce in valutazioni più alte: il gradimento medio resta sostanzialmente identico tra i tre generi."**

Interattività

Su questa pagina è stato aggiunto uno slicer per Genere (men/unisex/women), che permette di esplorare i due grafici filtrando per genere. Scelta consapevole: lo slicer non è stato replicato su ogni pagina della dashboard, ma solo qui e sulla pagina Prezzi e vendite, dove Genere è la dimensione di analisi effettivamente rilevante.

Domanda 4 — Profumi più amati

Layout a due colonne: tabella con i 10 profumi a Punteggio Più Amati più alto (filtro Primi N per valore, ordinamento decrescente) a sinistra, con Brand, Valutazione Media e Numero Voti Totali per dare contesto; grafico a barre orizzontali dello stesso ranking a destra, per un colpo d'occhio immediato sul divario tra i punteggi.

Correzione applicata in Fase 5: la colonna Perfume conteneva ancora gli slug grezzi di Fragrantica (es. "dior-homme-intense-2011"). È stata pulita in Power Query con lo stesso metodo già usato per Brand in Fase 2. La correzione si propaga automaticamente anche a Bridge_Perfume_Accords, che deriva dalla stessa query di origine.

Top 3 risultante: Dior Homme Intense 2011 (19,18) · La Nuit De L Homme, Yves Saint Laurent (19,05) · Le Male Le Parfum, Jean Paul Gaultier (18,99). Nessun valore anomalo di Numero Voti Totali, segno che non ci sono duplicati nascosti dietro il conteggio dei voti.

Testo aggiunto in rifinitura, per rendere accessibile la formula a chi guarda senza contesto tecnico: **"Il Punteggio Più Amati combina valutazione media e numero di voti (tramite una scala logaritmica), per evitare che un profumo con pochi voti ma un rating altissimo scavalchi profumi molto più votati e altrettanto apprezzati."**

Domanda 5 — Note di successo

La domanda più delicata dal punto di vista del modello: collegare il Punteggio Più Amati (una misura, calcolata per singolo profumo su Fra_Cleaned) agli accordi olfattivi (che vivono in Bridge_Perfume_Accords, collegata a Fra_Cleaned solo indirettamente tramite Dim_Brand, a livello di marca — non di singolo profumo).

Metodo scelto: individuare i 100 profumi con il punteggio più alto tramite due colonne calcolate su Fra_Cleaned (Punteggio Riga, Rank Punteggio con RANKX, Amato Top100 come etichetta Sì/No), poi collegare quell'insieme alla tabella degli accordi tramite TREATAS — una funzione che applica un filtro come se esistesse una relazione diretta tra due tabelle che condividono una colonna (qui: il nome del profumo), senza dover modificare lo schema a stella esistente.

```
Occorrenze Accordo Top100 =
CALCULATE(
  [Occorrenze Accordo],
  TREATAS(
    SELECTCOLUMNS(
      FILTER(Fra_Cleaned, Fra_Cleaned[Amato Top100] = "Sì"),
      "Perfume", Fra_Cleaned[Perfume]
    ),
    Bridge_Perfume_Accords[Perfume]
  )
)
```

Verifica di robustezza: prima di considerare il risultato affidabile, è stato controllato che nessuno dei 100 nomi di profumo selezionati fosse duplicato altrove nel dataset (24.063 righe totali) — una condizione necessaria perché TREATAS funziona per nome, non per identificativo univoco. Il controllo (misura di supporto Conteggio Nome Totale, con ALLEXCEPT) ha confermato: tutti i 100 nomi sono unici, nessuna collisione.

Risultato: le note più ricorrenti tra i profumi più amati sono woody (59 occorrenze), aromatic (43), citrus (41), amber (39), seguite da fresh spicy, sweet e warm spicy (35 ciascuna). Un profilo olfattivo coerente e plausibile per il segmento maschile/legnoso che domina la classifica dei più amati.

Correzione terminologica in rifinitura: l'asse e il titolo del grafico usavano impropriamente "Fragranze" per indicare le famiglie olfattive (woody, citrus...) — corretto in "Famiglia Olfattiva", poiché "fragranza" indica il singolo profumo, non l'accordo. Testo metodologico aggiunto: **"Il grafico mostra le famiglie olfattive più ricorrenti tra i 100 profumi con il punteggio più alto (non tra tutti i 24.063), per capire quali note caratterizzano davvero il successo, non solo la popolarità generica."**

Domanda 6 — Prezzi e vendite

Layout a griglia con quattro grafici sulla sola tabella Fact_eBay: Fatturato Stimato per Brand (Top 10, barre orizzontali), Fatturato Stimato per Genere, Prezzo Medio per Genere, Pezzi Venduti Totali per Genere — questi ultimi tre separati (non affiancati in un solo grafico) perché le scale molto diverse tra loro (decine di dollari per il prezzo, milioni per il fatturato) rendevano illeggibili due misure su tre se unite.

Risultato, verificato sui valori mostrati nel report: gli uomini superano le donne su tutti e tre gli indicatori — fatturato stimato **25,8Mln contro 13,9Mln**, prezzo medio **46$ contro 40$**, pezzi venduti **761.669 contro 489.363**. Un pattern coerente su tre misure indipendenti, non un'anomalia isolata.

Testo aggiunto in rifinitura: **"Gli uomini superano le donne su tutti e tre gli indicatori: fatturato stimato (25,8Mln contro 13,9Mln), prezzo medio (46$ contro 40$) e pezzi venduti (761.669 contro 489.363). Un pattern coerente su tre misure indipendenti, non un'anomalia isolata."**

Copertina (Presentazione)

Pagina di apertura completata in Fase 5: titolo "Il Mondo dei Profumi" (Constantia, 30pt, prugna, centrato) e sottotitolo "Analisi del mercato dei profumi tra marche, tendenze olfattive e vendite" (Calibri, 14pt, grigio, corsivo, centrato), sopra le cinque schede KPI (Numero Profumi, Numero Marche, Fatturato Stimato, Valutazione Media, Pezzi Venduti Totali), costruite con il valore in colore prugna del tema e allineate in fila.

Sotto le card, è stata aggiunta un'illustrazione di sette flaconi di profumo generata con intelligenza artificiale (Gemini) e adattata manualmente alla palette del tema (viola prugna, oro, verde salvia, rosa cipria, beige), per dare identità visiva alla pagina di apertura senza introdurre elementi fuori tono rispetto al resto della dashboard.

Fase 6 — Racconto finale e stato attuale

Fase	Contenuto	Stato
1. Impostazione	Obiettivi, fonti, domande, limiti	Completata
2. Pulizia dati	Power Query su tutte le fonti	Completata
3. Modello dati	Schema a stella con Dim_Brand	Completata
4. Misure DAX	13 misure: medie, conteggi, fatturato stimato, punteggi compositi	Completata
5. Dashboard	Copertina + 6 domande, tutte rifinite con testi di contesto, etichette dati e slicer	Completata
6. Racconto finale	README e relazione	Completata

Tutte e sei le domande della dashboard sono complete e rifinite, con titoli parlanti, etichette dati, testi metodologici e di insight, terminologia italiana coerente su assi e legende. La copertina è completa. Uno slicer per Genere è attivo sulle pagine dove è analiticamente rilevante (Genere e valutazioni, Prezzi e vendite).

Approfondimento valutato e correttamente scartato: è stata verificata l'ipotesi di una settima pagina dedicata alla variazione delle famiglie olfattive tra il 2000 e il 2019, riusando i dati già puliti per la Domanda 2. La verifica sui valori puntuali (Year=2000 vs Year=2019, per ciascuna delle 6 famiglie) ha mostrato variazioni contenute e senza un andamento dominante: nessuna famiglia guadagna o perde più di 2 punti percentuali. Costruire una pagina intera su un risultato privo di un insight forte avrebbe introdotto complessità senza valore reale, in contraddizione con il principio guida del progetto. La scelta finale, coerente con questo principio, è stata più sobria: aggiungere un'unica riga di testo sotto il grafico

della Domanda 2 con l'osservazione reale ("la composizione delle famiglie olfattive resta relativamente stabile nel tempo"), senza forzare una pagina aggiuntiva pur di produrne una.

— Fine della Relazione Riepilogativa (Fasi 1–6) — Progetto completo —